

**Klasifikasi Penyakit pada Daun Padi Menggunakan
Local Binary Pattern (LBP) dan *Support Vector Machine (SVM)***

Tugas Akhir

diajukan untuk memenuhi salah satu syarat

memperoleh gelar sarjana

dari Program Studi S1 Informatika

Fakultas Informatika

Universitas Telkom

1301163617

Simiao Salvador da Gama



Program Studi Sarjana Informatika

Fakultas Informatika

Universitas Telkom

Bandung

2020

LEMBAR PENGESAHAN

Klasifikasi Penyakit pada Daun Padi Menggunakan *Local Binary Pattern (LBP)* dan *Support Vector Machine (SVM)*

Rice Leaf Disease Classification Using *Local Binary Pattern (LBP)* and *Support Vector Machine (SVM)*

NIM : 1301163617

Simiao Salvador da Gama

Tugas akhir ini telah diterima dan disahkan untuk memenuhi sebagian syarat memperoleh gelar pada Program Studi Sarjana Studi Sarjana Informatika

Fakultas Informatika

Universitas Telkom

Bandung, 7 Agustus 2020

Menyetujui

Pembimbing I,



Kurniawan Nur Ramadhani, S.T., M.T.

NIP: 14880009

Pembimbing II,



Febryanti Sthevanie, S.T., M.T.

NIP: 14880014

Ketua Program Studi
Sarjana Informatika.



Niken Dwi Wahyu Cahyani, ST., M.Kom., Ph.D

NIP: 00750052

LEMBAR PERNYATAAN

Dengan ini saya, Simiao Salvador da Gama, menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul Klasifikasi Penyakit pada Daun Padi Menggunakan *Local Binary Pattern* (LBP) dan *Support Vector Machine* (SVM) beserta dengan seluruh isinya adalah merupakan hasil karya sendiri, dan saya tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang berlaku dalam masyarakat keilmuan. Saya siap menanggung resiko/sanksi yang diberikan jika di kemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam buku TA atau jika ada klaim dari pihak lain terhadap keaslian karya,

Bandung, 7 Agustus 2020

Yang Menyatakan



Simiao Salvador da Gama

Klasifikasi Penyakit pada Daun Padi Menggunakan *Local Binary Pattern* (LBP) dan *Support Vector Machine* (SVM)

Simiao Salvador da Gama¹, Kurniawan Nur Ramadhani², Febryanti Sthevanie³

^{1,2,3}Fakultas Informatika, Universitas Telkom, Bandung

¹simiao@student.telkomuniversity.ac.id, ²kurniawanr@telkomuniversity.ac.id,

³sthevanie@telkomuniversity.ac.id

Abstrak

Indonesia merupakan negara yang memiliki angka kebutuhan beras yang tinggi. Hal ini mengharuskan petani untuk memproduksi beras dalam angka yang besar dan dengan kualitas yang baik. Namun adanya penyakit pada tanaman sehingga menyebabkan berkurangnya kualitas dan kuantitas hasil tani. Daun padi merupakan bagian yang paling penting sebagai langkah awal deteksi penyakit pada padi. Hal ini disebabkan daun memiliki penampang yang luas dibandingkan bagian tubuh tanaman padi yang lain, sehingga perubahan warna dan bentuk dapat terlihat lebih jelas. Pada penelitian ini melakukan klasifikasi penyakit yang ada pada daun padi melalui operasi citra digital. Metode yang digunakan untuk mengidentifikasi bentuk gejala penyakit padi adalah gabungan ekstraksi fitur *Local Binary Pattern* (LBP) dan warna dan klasifikasi *Support Vector Machine* (SVM). Hasil dari penelitian ini memiliki kinerja sistem yang baik sebesar 98.33%.

Kata Kunci: Citra Digital, *Support Vector Machine*, *Local Binary Pattern*

Abstract

Indonesia is a country that has a high number of rice needs. This requires farmers to produce rice in large numbers and with good quality. However, the existence of diseases in plants causes reduced quality and quantity of rice. Rice leaves are the most important part as the first step to detect disease in rice. This is because the leaves have a broad cross section compared to the rest of the rice plants, so that changes in color and shape can be seen more clearly. In this research we identify and classify diseases that exist in rice leaves through digital image processing. The method that we use to identify forms of rice disease symptoms is *Local Binary Pattern* (LBP) and *Color Feature* using *Support Vector Machine* (SVM) classification. In this research we successfully get an accuracy 98.33%.

Keyword: Digital image processing, *Local Binary Pattern*, *Support Vector Machine*

1. Pendahuluan

Latar Belakang

Di sektor pertanian, padi menghadapi masalah serius karena sering terdapat berbagai penyakit yang menyerang sehingga menurunkan produktivitas dari segi kualitas maupun kuantitas [10]. Penyakit yang ada pada tanaman padi dipengaruhi oleh jamur dan bakteri sehingga gejala tersebut dapat dilihat pada beberapa bagian padi, seperti daun, batang, dan akar, jika tidak diatasi secepat maka akan menyebabkan kerugian besar[3]. Gejala penyakit yang ada pada tanaman padi yang paling mudah diidentifikasi adalah daun karena bagian tersebut memiliki penampang yang lebih luas dibandingkan bagian tanaman padi yang lain, sehingga perubahan warna dan bentuk bercak dapat terlihat lebih jelas.[5]

Pada penelitian sebelumnya yakni pada tahun 2017 sudah melakukan deteksi dan klasifikasi penyakit pada daun padi dengan metode *SVM* dengan ekstraksi ciri warna, bentuk dan tekstur dan mencapai klasifikasi akurasi sebesar 73,33%[5]. Pada tahun 2016 telah melakukan juga penelitian tentang diskriminasi tanaman menggunakan metode *Local Binary Pattern* dan *Multiclass Support Vector Machine* (MSVM) yang efektif dengan akurasi 91,85% [7]. Oleh karena itu pada penelitian ini penulis membuat sistem klasifikasi penyakit yang terjangkau pada daun padi menggunakan *Local Binary Pattern* dan *Support Vector Machine* dengan tujuan untuk meningkatkan akurasi dalam pengenalan dan klasifikasi penyakit yang ada pada daun padi.

Topik dan Batasannya

Berdasarkan latar belakang masalah penelitian ini, dapat disimpulkan bahwa topik permasalahan yang diselesaikan yaitu bagaimana mengklasifikasi penyakit yang ada pada daun padi menggunakan ekstraksi ciri *Local Binary Patterns* (LBP) dan bagaimana kinerja dari sistem yang dibangun.

Batasan permasalahan pada penelitian ini yaitu: dataset terbagi 2 (dua) bagian yaitu dataset pelatihan dan dataset pengujian. Dataset pelatihan meliputi 540 citra pada setiap kelas penyakit yaitu *bacterial leaf blast*, *brown spot* dan *Leafsmut*. Dataset pengujian terdapat 120 citra pada setiap kelas penyakit sama seperti dataset pelatihan.

Jumlah dataset keseluruhan adalah 660 citra yang dibagi ke dalam data latih dan data pengujian. Resolusi citra yang digunakan adalah 256x256.

Tujuan

Tujuan dari penelitian Tugas Akhir (TA) adalah membangun sebuah sistem yang dapat mengklasifikasikan tiga jenis penyakit yang ada pada daun padi menggunakan ekstraksi fitur *Local Binary Patterns* (LBP) dan menghitung kinerja dari sistem yang dibangun.

Organisasi Tulisan

Struktur daripada penulisan ini adalah sebagai berikut: bagian pertama menjelaskan pendahuluan. Bagian kedua menjelaskan studi terkait. Bagian ketiga menjelaskan sistem yang dibangun. Bagian keempat menjelaskan evaluasi dari kinerja sistem yang dibangun. Bagian kelima menjelaskan tentang kesimpulan.

2. Studi Terkait

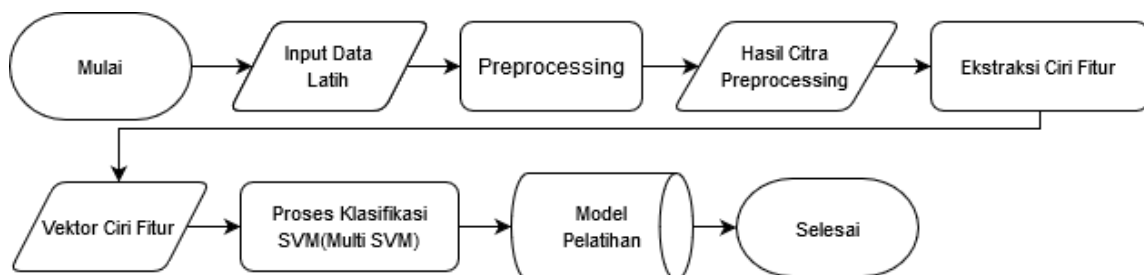
Penelitian mengenai klasifikasi penyakit pada daun padi telah dilakukan oleh K. Jagan Mohan et al [1] menggunakan metode AdaBoost, SVM dan KNN dimana dapat mendeteksi dan mengenali penyakit pada daun padi yaitu : *Brown spot*, *Leaf blast* dan *Bacterial blight* . Metode AdaBoost dapat mendeteksi penyakit dengan akurasi 83.33% sedangkan untuk mengklasifikasi penyakit pada daun padi menggunakan metode SVM dan KNN yang menghasilkan akurasi 91.10% dan 93.33%. Harshadkumar B. Prajapati et al [5] juga melakukan penelitian klasifikasi penyakit pada daun padi dengan gabungan beberapa teknik ekstraksi fitur yaitu ekstraksi fitur berdasarkan warna dan tekstur. Pada penelitian ini mampu mendeteksi dan mengklasifikasi penyakit yang ada pada daun padi karena menggunakan beberapa teknik removal background meskipun ada beberapa *background* yang berbeda beda.

Sementara penelitian menggunakan ekstraksi ciri *Local Binary Pattern*(LBP) telah dilakukan oleh Y. M. Oo et al [4]. Pada penelitian tersebut menggunakan ekstraksi ciri *Gray Level Co Occurrence Matrix*(GLCM) dan *Local Binary Patterns* (LBP) untuk mengklasifikasi penyakit pada daun tanaman. Metode ini mampu mengenali penyakit pada daun tanaman yang berbeda beda dan hasil percobaan menunjukkan bahwa sistem yang diusulkan dapat berhasil mendeteksi dan mengklasifikasikan empat penyakit daun tanaman : *Bacterial Blight*, *Cercospora Leaf Spot*, *Powdery Mildew* dan *Rust* dan mampu mencapai akurasi sebesar 91.85%. P. B. Padol et al[6] menggunakan *Local Binary Pattern* dan *Hierarchical Contour Analysis* untuk mendeteksi buah yang belum matang. Metode yang diusulkan mampu mendeteksi buah jeruk yang belum matang dengan dievaluasi dengan 25 gambar data test dimana hasil akurasi hampir sampai 80.4% untuk rasio positif yang benar, 82.3% untuk presisi, dan 81.3 untuk F-measures.

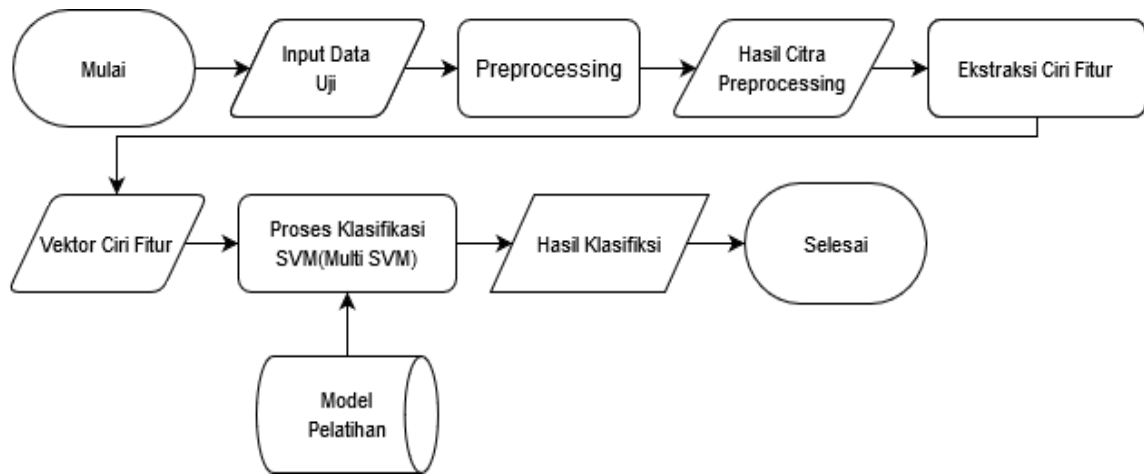
3. Sistem yang Dibangun

3.1 Skema Sistem

Secara umum sistem klasifikasi yang dibangun pada tugas akhir ini dibagi ke dalam dua bagian, yaitu proses latih(*training*) dan proses pengujian(*testing*). Pada proses latih dihasilkan sebuah model klasifikasi yang berfungsi untuk melakukan klasifikasi penyakit pada daun padi, sedangkan pada proses pengujian dihasilkan hasil dari klasifikasi penyakit yang terjangkit pada daun padi yaitu berupa label penyakit pada setiap citra. Berikut ini adalah diagram alir dari tahap pembangunan model klasifikasi pada proses latih(*training*) dan uji(*testing*).



Gambar 1. Alur skema pelatihan



Gambar 2. Alur skema pengujian

3.2 Data Masukan

Pada tahap ini data yang digunakan dalam pengembangan model klasifikasi penyakit pada daun padi adalah tiga buah dataset berupa foto daun padi yang dapat diunduh di situs <https://archive.ics.uci.edu/ml/datasets/Rice+Leaf+Diseases>.



Gambar 3. Perbandingan daun padi yang terjangkit penyakit

Tabel 1. Karakteristik penyakit pada daun padi

No	Nama Penyakit	Bentuk Gejala	Warna Lesi
1	Bacterial Leaf Blight	Lesi memanjang dalam beberapa inci di tepi atau ujung daun	Kuning putih karena efek bakteri
2	Brown Spot	Bentuk bulat seperti oval	Cokelat kemerahan seperti cokelat tua
3	Leaf Smut	Bintik-bintik kecil tersebar di seluruh daun dalam bentuk yang tidak seragam	Cokelat kemerahan

Jumlah data latih yang digunakan pada penelitian ini adalah 540 data dengan dilakukan augmentasi data seperti rotasi sebesar 90° dan 180° yang terdiri dari tiga kelas penyakit yaitu *Bacterial Leaf Blight*, *Brown Spot* dan *Leaf Smut*. Sedangkan jumlah data pengujian adalah 120 yang dibagi ke tiga kelas penyakit seperti di data latih.


3.3 Preprocessing

3.3.1 Segmentasi Citra

Segmentasi citra adalah proses untuk memisahkan antara objek *background* dengan *foreground*. Pada tahap segmentasi ini, citra yang dimasukan dilakukan nilai *threshold minimum* dan *maximum* pada ruang warna HSV sehingga mampu memisahkan bagian yang terjangkit penyakit dan tidak, dimana bagian yang tidak terjangkit penyakit seperti *background* citra dan daun akan diubah menjadi warna hitam. Hasil jenis warna citra pada proses ini masih dalam bentuk RGB dan dari citra ini diambil fitur warna pada proses ekstraksi ciri warna.

Proses yang dilakukan pada saat thresholding citra :

- Ubah citra RGB ke citra HSV
- Tentukan nilai threshold histogram minimum dan maximum pada setiap channel HSV
- Membuat mask berdasarkan histogram threshold yang dipilih.
- Invert mask
- Inisialisasi citra output yang di-mask berdasarkan citra input (citra RGB)
- Tentukan nilai piksel background dimana terdapat bukan mask menjadi nol.



Gambar 4. Perubahan citra RGB ke citra tersegmentasi

3.3.2 HSV

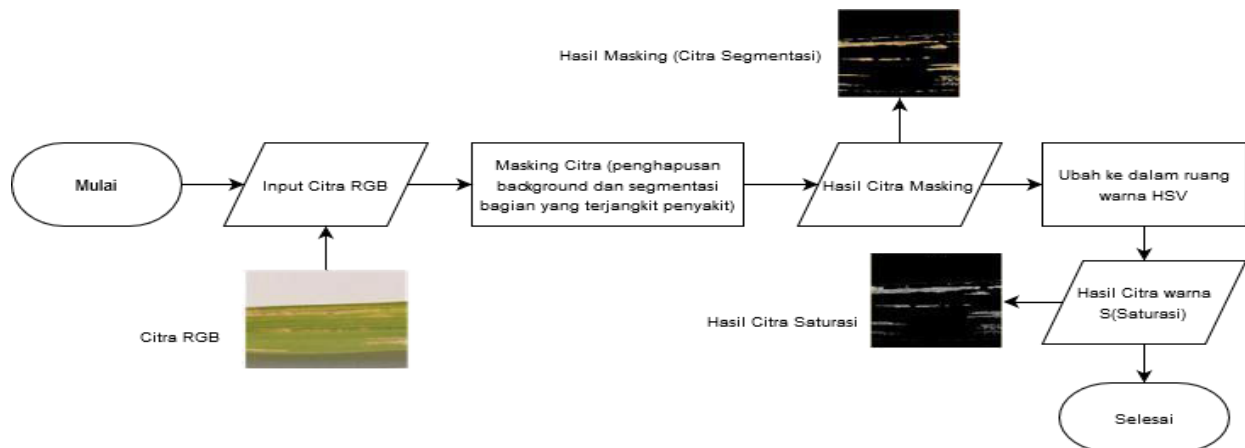
Ruang warna pada umumnya memiliki tiga komponen utama yang merupakan representasi warna primer, yaitu merah, hijau dan biru (RGB). Selain ruang warna RGB karakteristik persepsi mata manusia dalam membedakan satu warna dengan warna yang lain berupa HSV (*hue, saturation, dan value*) [5].

- *Hue* merupakan warna yang menunjukkan seperti merah dan hijau.
- *Saturation* merupakan level kemurnian dari suatu warna atau nilai yang menunjukkan tingkat kejenuhan . Semakin besar nilai saturasi maka semakin murni warna yang dihasilkan.
- *Value* merupakan nilai yang menunjukkan tingkat kecerahan warna.

Berikut adalah persamaan ruang warna *HSV*.

$$\begin{aligned}
 r &= \frac{R}{(R+G+B)}, \quad g = \frac{G}{(R+G+B)}, \quad b = \frac{B}{(R+G+B)} \\
 V &= \max(r,g,b) \\
 S &= \begin{cases} 0, & \text{jika } V = 0 \\ 1 - \frac{\min(r,g,b)}{V}, & \text{jika } V > 0 \end{cases} \\
 H &= \begin{cases} 0, & \text{jika } S = 0 \\ \frac{60 \cdot (g-b)}{S \cdot V}, & \text{jika } V = r \\ 60 \cdot \left[2 + \frac{b-r}{S \cdot V} \right], & \text{jika } V = g \\ 60 \cdot \left[4 + \frac{r-g}{S \cdot V} \right], & \text{jika } V = b \end{cases} \\
 H &= H + 360, \quad \text{jika } H < 0
 \end{aligned}
 \tag{1}$$

Setelah mendapatkan hasil segmentasi citra (*masking citra*) dilakukan pengubahan ke dalam ruang warna HSV. Ambil ruang warna Saturasi untuk melakukan ekstraksi ciri LBP pada tahap selanjutnya[5].

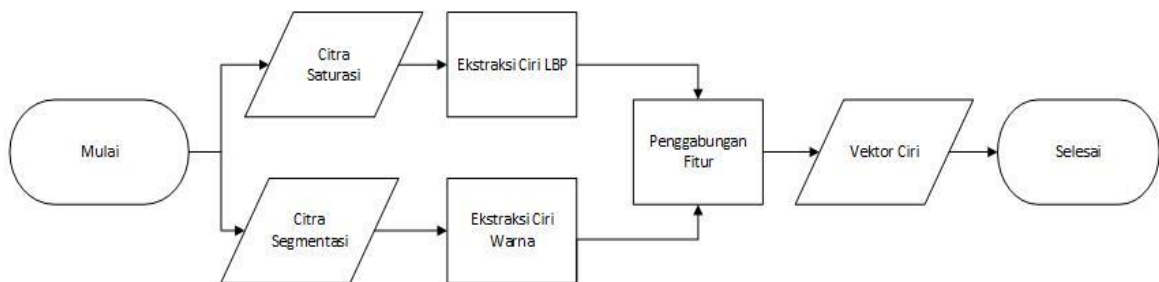


Gambar 5. Flowchart Pre-processing

Tujuan dari Pre-processing adalah menghilangkan *noise* atau memperjelas fitur sehingga memudahkan sistem pada saat ekstraksi ciri fitur. Hasil citra preprocessing yang digunakan pada proses ekstraksi ciri selanjutnya adalah citra tersegmentasi untuk ekstraksi ciri warna, dan citra saturasi untuk ekstraksi ciri LBP. Pada proses ini digunakan citra tersegmentasi pada ekstraksi ciri fitur warna karena citra ini menunjukkan bagian tertentu yang terkena penyakit sehingga memudahkan pada saat klasifikasi. Untuk ekstraksi ciri LBP digunakan citra *saturation* dari ruang warna HSV karena citra saturasi menunjukkan kemurnian dari suatu warna atau nilai yang menunjukkan tingkat kejenuhan.

3.4 Ekstraksi Ciri


Proses ekstraksi ciri bertujuan untuk mengambil ciri pada citra agar dapat diklasifikasi pada proses klasifikasi. Metode yang digunakan untuk melakukan ekstraksi ciri pada penelitian ini adalah gabungan antara fitur ciri *Local Binary Pattern* dan fitur ciri warna. Metode ini dipilih karena dengan menggunakan fitur *Local Binary Pattern* dan warna dapat mengekstraksi ciri dalam bentuk tekstur dan warna pada daun padi yang dapat digunakan untuk mengklasifikasi penyakit tersebut masuk dalam kelas yang mana.



Gambar 6. Flowchart Ekstraksi Fitur

3.4.1 Local Binary Pattern (LBP)

LBP adalah salah satu metode ekstraksi fitur dari suatu citra digital. Metode ini diperkenalkan oleh Ojala et al pada tahun 1996. Local Binary Pattern digunakan untuk mendapatkan tekstur dan bentuk dari suatu citra digital dengan cara menghitung perbandingan lebih besar atau kecil setiap piksel dengan piksel ketetanggaan [2].



Gambar 7. Ilustrasi Local Binary Pattern [7]


Pada Gambar 1, fitur yang didapat di setiap piksel berupa pola biner yang mewakili piksel tersebut. Setiap pola biner yang didapat kemudian dikonversi menjadi angka desimal kemudian disatukan untuk membentuk fitur histogram yang merupakan representasi dari citra digital tersebut. *Local Binary Pattern* dapat diformulasikan sebagai berikut :

$$LBP_{P,R} = \sum_{p=0}^{P-1} S(g_p - g_c) 2^p \quad \dots\dots\dots (2)$$

$$S(z) = \begin{cases} 1, & z \geq 0 \\ 0, & z < 0 \end{cases} \quad \dots\dots\dots (3)$$

Proses yang dilakukan oleh metode *Local Binary Pattern* memiliki beberapa langkah yaitu :

1. Tentukan berapa banyak piksel sampel yang akan dibandingkan dengan piksel pusat.
2. Tentukan seberapa besar radius atau jarak piksel pusat dengan piksel sampel.
3. Bandingkan nilai setiap piksel sampel dengan piksel pusat untuk menghasilkan nilai biner.
4. Ubah nilai biner yang telah didapat ke dalam nilai desimal.



Gambar 8. Proses pembuatan histogram pada metode Local Binary Pattern

Untuk melakukan proses ekstraksi ciri citra pada penelitian ini, citra saturasi daun padi dibagi ke dalam beberapa bagian dengan jumlah tertentu yang diberi nama ukuran grid. Setiap bagian pada citra akan dikonversikan menggunakan metode *Local Binary Pattern*. Setelah semua bagian dikonversi dengan menggunakan metode *Local Binary Pattern*, setiap bagian citra akan dihitung seberapa banyak persebaran nilai piksel yang ada guna mendapatkan histogram dari setiap bagian citra. Histogram yang telah didapat pada setiap bagian pada citra selanjutnya akan digabungkan dengan histogram pada bagian citra yang lain, seperti dilihat di Gambar 8.

3.4.2 Fitur Warna


Histogram Warna adalah teknik yang paling banyak digunakan untuk mengekstraksi fitur warna gambar. Histogram Warna diusulkan sebagai deskriptor warna global yang menganalisis setiap frekuensi warna statistik dalam suatu gambar.

Pada penelitian ini, fitur warna yang digunakan adalah nilai rata-rata pada setiap warna (merah, hijau dan biru) dari ruang warna RGB (citra tersegmentasi) dan standard deviasi pada warna merah (*red*) dari ruang warna RGB (citra tersegmentasi).

Hasil dari penggabungan fitur LBP dan warna digunakan pada proses klasifikasi.

3.5 Klasifikasi

SVM merupakan sistem pembelajaran yang menggunakan ruang hipotesis berupa fungsi-fungsi linier dalam sebuah ruang ciri berdimensi tinggi, dan dilatih menggunakan algoritma yang didasarkan teori optimasi dengan implementasi pembelajaran biasa yang berasal dari teori pembelajaran statistik yang digunakan untuk klasifikasi dan regresi data [1].



Gambar 9. Hyperplane terhadap 2 kelas vector [6]

Gambar 9 di atas merupakan ilustrasi arsitektur SVM yang mencari hyperplane pemisah antar class, SVM berusaha menemukan *hyperplane* yang terbaik pada *input space*.


SVM linear menggunakan *hyperplane* yang disebut batas keputusan antara dua kelas. *Hyperplane* ini akan mencoba untuk membagi, satu kelas berisi vektor pelatihan target yang dilabeli sebagai +1, dan kelas lainnya berisi vektor pelatihan yang diberi label -1 [6]. Dalam melakukan *learning* pada klasifikasi *SVM* melibatkan pemasangan *hyperplane* sehingga margin terbesar terbentuk antara 2 kelas vektor sambil meminimalkan efek kesalahan klasifikasi. [8]

$$g(x) = \omega^t x + b \quad \dots \dots \dots (4)$$

$$\text{dimana } \begin{cases} y_i = +1, & g(x_i) \geq 0 \\ y_i = -1, & g(x_i) < 0 \end{cases}$$

Dengan kata lain, sampel pelatihan dari dua kelas yang berbeda dilepaskan oleh hyperplane $g(x) = \omega^T x + b = 0$

Untuk data yang dapat dipisahkan secara non-linear, ini dapat menggambarkan data dalam ruang input ke dalam ruang dimensi tinggi dengan fungsi kernel $\Theta(x)$, untuk menemukan *hyperplane* pemisah.



Gambar 10. Klasifikasi SVM Non-Linear [8]

Untuk menyelesaikan problem non-linear, SVM dimodifikasi dengan memasukkan fungsi Kernel. Dalam non-linear SVM, pertama-tama data x dipetakan oleh fungsi $\Theta(x)$, ruang vektor yang berdimensi lebih tinggi. Pada ruang vektor yang baru ini, *hyperplane* yang memisahkan kedua kelas tersebut dapat dikonstruksikan.

Pada penelitian ini, metode klasifikasi yang dipilih adalah Multi Class Support Vector Machine karena memiliki 3(tiga) kelas dataset. *Kernel* yang digunakan adalah *rbf*, *linear* dan *polynomial*.

Multiclass SVM pada dasarnya terdiri dari modul pembelajaran dan modul klasifikasi, di mana model klasifikasi diterapkan pada data baru. Ini dapat diimplementasikan dengan mengubah SVM kelas tunggal menjadi kelipatan klasifikasi biner yang dapat dilakukan dengan membedakan pengklasifikasi berdasarkan label tertentu vs sisanya (one-vs-all) atau antara setiap pasangan kelas (one-vs-one). One-vs-all didasarkan pada pembelajaran kompetitif karena pemenang mengambil semua kredit sebagai pengklasifikasi dengan fungsi output tertinggi menetapkan fungsi sedangkan one-vs-one melibatkan prinsip pemenang suara maksimum, di mana setiap classifier menetapkan suara untuk salah satu dari dua kelas, dan akhirnya kelas dengan suara terbanyak menentukan pemenang.

Pada penelitian ini penulis menerapkan skema pengklasifikasi one-vs-one.

4. Evaluasi

4.1 Pengukuran Kinerja Sistem

Untuk mengukur kinerja sistem dari model, dibutuhkan Confusion Matrix yang dapat merepresentasikan performansi sistem yang telah dibangun. Cara kerja Confusion Matrix adalah untuk membandingkan hasil dari prediksi klasifikasi dengan hasil seharusnya yang didapat dari klasifikasi.

Tabel 2. Confusion Matrix

		LABEL PREDIKSI		
		Bacterial Leaf Blight	Brown Spot	Leaf Smut
LABEL SEBENARNYA	Bacterial Leaf Blight	T_{BLB}	$FBLB_{BS}$	$FBLB_{LS}$
	Brown Spot	FBS_{BLB}	T_{BS}	FBS_{LS}
	Leaf Smut	FLS_{BLB}	FLS_{BS}	T_{LS}

Berdasarkan Tabel. 2, T_{BLB} (*True Bacterial Leaf Blight*) merupakan jumlah data *Bacterial Leaf Blight* yang terklasifikasi dengan benar oleh sistem. T_{BS} (*True Brown Spot*) merupakan jumlah data *Brown Spot* yang terklasifikasi dengan benar oleh sistem. T_{LS} (*True Leaf Smut*) merupakan jumlah data *Leaf Smut* yang terklasifikasi dengan benar. FBS_{BLB} merupakan jumlah data *Bacterial Leaf Blight* yang terklasifikasi sebagai *Brown Spot*. FLS_{BLB} merupakan jumlah data *Bacterial Leaf Blight* yang terklasifikasi sebagai *Leaf Smut*. $FBLB_{BS}$ merupakan jumlah data *Brown Spot* yang terklasifikasi sebagai *Bacterial Leaf Blight*. FLS_{BS} merupakan jumlah data *Brown Spot* yang terklasifikasi sebagai *Leaf Smut*. $FBLB_{LS}$ merupakan jumlah data *Leaf Smut* yang terklasifikasi sebagai *Bacterial Leaf Blight*. FBS_{LS} merupakan jumlah data *Leaf Smut* yang terklasifikasi sebagai *Brown Spot*.

Berikut adalah perhitungan akurasi dengan persamaan berikut :

$$Accuracy = \frac{T_{BLB} + T_{BS} + T_{LS}}{T_{BLB} + T_{BS} + T_{LS} + FBS_{BLB} + FLS_{BLB} + FBLB_{BS} + FLS_{BS} + FBLB_{LS} + FBS_{LS}}$$

4.2 Skenario Pengujian

Dalam penelitian ini, diuji 2 skenario pengujian yang berbeda, yaitu:

1. Skenario 1: Pada skenario ini melakukan percobaan pengujian menggunakan k-folds dengan nilai $k = 10$. Pada pengujian ini diuji coba menggunakan ketiga kernel klasifikasi SVM yaitu: *linear*, *polynomial* dan *gaussian(rbf)*.
2. Skenario 2 : Pada skenario ini melakukan pengujian dan perbandingan ekstraksi fitur antara LBP dan gabungan ekstraksi fitur LBP dengan warna dengan parameter *radius*, dan *number of neighbours* yang berbeda. Pembangunan model dievaluasi menggunakan model SVM dengan kernel yang terbaik didapatkan dari skenario sebelumnya. Tujuan dari skenario ini adalah mengukur kinerja ekstraksi fitur data uji yang digunakan pada sistem.

4.3 Analisis Pengujian

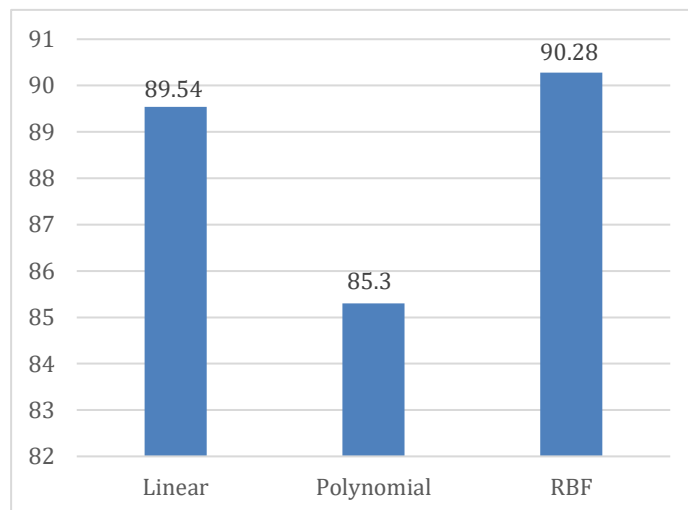
Setelah melakukan pengujian berikut adalah hasil pengujian beserta analisisnya pada setiap skenario :

1. Skenario 1

Pada skenario ini dilakukan pembangunan model yang dievaluasi dengan SVM data latih dengan *Cross Validation* menggunakan $k = 10$ karena dari banyak percobaan nilai ini menghasilkan perkiraan tingkat kesalahan pengujian yang sedikit dari bias yang terlalu tinggi maupun dari varians yang sangat tinggi. Model latih yang dievaluasi adalah model latih dari 3 (tiga) kernel SVM, yaitu *rbf*, *linear* dan *polynomial*. Strategi yang dipakai dalam SVM multi class adalah strategi one vs one. Strategi parameter LBP yang diuji adalah $r = 1$, $p = 8$ sebagai parameternya. Hasil yang diharapkan adalah mendapatkan akurasi terbaik dari ketiga kernel SVM.

Tabel 3. Pembangunan model cross validation dengan nilai $k = 10$ dan 3 kernel SVM

Kernel	Akurasi
RBF	90,28
Linear	89,54
Polynomial	85,3



Gambar 11. Perbandingan hasil Akurasi menggunakan 3 Kernel SVM

Pada skenario pengujian ini menunjukkan bahwa model SVM dengan kernel *rbf* memiliki akurasi yang lebih bagus dibanding dengan kedua kernel yang lainnya. Kernel *rbf* memiliki akurasi yang lebih bagus dibanding dengan kernel *linear* dan *polynomial* karena kernel *rbf* pada umumnya lebih fleksibel daripada kernel *linear* atau *polynomial* sehingga dapat memodelkan lebih banyak fungsi dengan ruang fungsinya. Oleh karena itu untuk pengujian pada skenario selanjutnya akan menggunakan klasifikasi model SVM dengan kernel *rbf*.

2. Skenario 2

Pada Skenario ini dilakukan pengujian dan perbandingan model ekstraksi ciri fitur LBP, warna dan gabungan antara fitur LBP dengan warna beserta parameternya yaitu nilai *radius* dan *neighbor*. Untuk tahap klasifikasi ini menggunakan *multi-SVM* dengan kernel *rbf*.



Tabel 4. Pengujian fitur LBP dan gabungan fitur LBP dan warna dengan parameternya

Metode	Akurasi	Panjang Vektor
LBP(1,4)	78,33	16
LBP(1,8)	88,33	256
LBP(2,8)	87,5	256
Fitur Warna	88,33	4
Penggabungan LBP(1,4) dengan Fitur warna	95,83	20
Penggabungan LBP(1,8) dengan Fitur warna	97,5	260
Penggabungan LBP(2,8) dengan Fitur warna	98,33	260

Berdasarkan eksperimen yang dilakukan, gabungan fitur ciri LBP dengan fitur ciri warna dengan radius=2 dan neighbor=8 mampu mengklasifikasi penyakit pada daun padi dengan akurasi lebih tinggi dibanding dengan yang lainnya yaitu akurasi sebesar 98.33%.

Berikut adalah Citra yang salah terprediksi.

Tabel 5. Data Kesalahan Prediksi Citra Leaf Smut menjadi Brown Spot

Citra	Kelas Sebenarnya dan Kelas terprediksi	Euclidean Distance antara fitur citra terhadap nilai rata rata fitur pada setiap Kelas		
		Bacterial Leaf Blight	Brown Spot	Leaf Smut
 Leafsmut_114	Leaf Smut terprediksi sebagai Brown Spot	1.28	1.26	1.27
 Leafsmut_16	Leaf Smut terprediksi sebagai Brown Spot	1.29	1.28	1.29

Dapat terlihat bahwa jarak *euclidean* antara citra *Leafsmut_114* dan *Leafsmut_116* yang paling dekat adalah 1,26 dan 1,28 dari kelas *Brown Spot* sehingga kedua citra tersebut dapat diklasifikasi sebagai kelas *Brown Spot*.

Tabel 6. Perbandingan akurasi dengan penelitian sebelumnya

Penulis	Fitur	Classifier	Akurasi (%)
Harshadkumar B. Prajapati et al[5]	Color + Shape + Texture	SVM	73,33
Kawcher Ahmed et al [12]	Color	Decision Tree	97,91
Sistem yang Diajukan	Texture+Color	SVM	98,33

Dari hasil yang diperoleh dari tes, akurasi sistem yang diusulkan lebih baik dibandingkan dengan studi sebelumnya yang menggunakan dataset yang sama. Perbandingan hasil sistem penelitian yang dibuat sebelumnya menunjukkan bahwa pada Tabel 4 sistem yang diajukan mampu mencapai akurasi sebesar 98,33 menggunakan gabungan ekstraksi ciri *LBP* dan warna dan diklasifikasi dengan *SVM*. Dengan demikian klasifikasi penyakit pada daun padi menggunakan *LBP* dan *SVM* pada penelitian ini memiliki akurasi yang lebih tinggi dibanding dengan penelitian sebelumnya.

5 Kesimpulan

Pada penelitian ini, telah dibangun sistem klasifikasi penyakit pada daun padi menggunakan *Local Binary Pattern* dan *Support Vector Machine*. Berdasarkan penelitian yang telah dilakukan, maka dapat disimpulkan bahwa sistem ini dapat mengklasifikasi penyakit pada daun padi menggunakan gabungan ekstraksi ciri *LBP* dan warna dan diklasifikasi menggunakan *SVM* memiliki akurasi yang lebih tinggi dibanding dengan penelitian sebelumnya dengan mencapai akurasi kinerja sistem sebesar 98,33%.

Untuk penelitian selanjutnya dapat diujikan dengan data yang lebih besar dengan berbagai kelas penyakit. Selain itu, pada penelitian selanjutnya dapat dikombinasikan deteksi bagian mana yang terjangkit penyakit.

DAFTAR PUSTAKA

- [1] K. Jagan, M. Balasubramanian, and S. Palanivel, "Detection and Recognition of Diseases from Paddy Plant Leaf Images," *Int. J. Comput. Appl.*, vol. 144, no. 12, pp. 34–41, 2016.
- [2] J. Lu, W. Suk, H. Gan, and X. Hu, "ScienceDirect Immature citrus fruit detection based on *Local Binary Pattern* feature and hierarchical contour analysis," *Biosyst. Eng.*, vol. 171, pp. 78–90, 2018.
- [3] K. K. Zaw, "Support Vector Machine Based Classification of Leaf Diseases," vol. 7, no. 08, pp. 143–147, 2018.
- [4] Y. M. Oo and N. C. Htun, "Plant Leaf Disease Detection and Classification using Image Processing," *Int. J. Res. Eng.*, vol. 5, no. 9, pp. 516–523, 2018.
- [5] H. B. Prajapati, J. P. Shah, and V. K. Dabhi, "Detection and classification of rice plant diseases," *Intell. Decis. Technol.*, vol. 11, no. 3, pp. 357–373, 2017.
- [6] P. B. Padol and A. A. Yadav, "SVM classifier based grape leaf disease detection," *Conf. Adv. Signal Process. CASP 2016*, pp. 175–179, 2016.
- [7] V. Nguyen, T. Le, B. Apopei, and K. Alameh, "Effective plant discrimination based on the combination of *Local Binary Pattern* operators and multiclass *Support Vector Machine* methods," *Inf. Process. Agric.*, vol. 6, no. 1, pp. 116–131, 2019.
- [8] A. Datta, A. Dey, and K. N. Dey, *Automatic Multiclass Classification of Foliar Leaf Diseases Using Statistical and Color Feature Extraction and Support Vector Machine*, vol. 2. Springer Singapore, 2019.
- [9] K. Singh, S. Kumar, and P. Kaur, "Support Vector Machine classifier based detection of fungal rust disease in Pea Plant (*Pisum sativum*)," *Int. J. Inf. Technol.*, 2018.
- [10] S. Ramesh, "Rice Blast Disease Detection and Classification using Machine Learning Algorithm," *2018 2nd Int. Conf. Micro-Electronics Telecommun. Eng.*, pp. 255–259, 2018.
- [11] H. Waghmare, R. Kokare and Y. Dandawate, "Detection and classification of diseases of Grape plant using opposite colour *Local Binary Pattern* feature and machine learning for automated Decision Support System," *2016 3rd International Conference on Signal Processing and Integrated Networks (SPIN)*, Noida, 2016.
- [12] K. Ahmed, T. R. Shahidi, S. M. Irfanul Alam, and S. Momen, "Rice leaf disease detection using machine learning techniques," *2019 Int. Conf. Sustain. Technol. Ind. 4.0, STI 2019*, vol. 0, pp. 1–5, 2019, doi: 10.1109/STI47673.2019.9068096.